



Análisis de hechos estilizados en series de tiempo
Reporte 17 de Marzo

Autor: Leonel Jose Evans Gonzalez

Asesor: Dr Nelson Muriel
Lectores: Dr. Eliud Silva, Mtro. Andres Olmos

Abstract

Este proyecto tiene como objetivo analizar hechos estilizados en series temporales de precios de acciones y probar si pueden usarse para predecir ciertos comportamientos y generar ganancias adicionales utilizando modelos estadísticos. Se han descargado y analizado los datos de las 500 empresas que componen el índice Standard & Poor's 500 durante los últimos 10 años. El proyecto contrasta las visiones de diferentes autores sobre la importancia de los hechos estilizados y si son compatibles con un modelo de mercado eficiente o si pueden ser explotados para generar ingresos adicionales. Los datos se limpiaron y analizaron para determinar el mejor modelo de ajuste usando la función autoarima.

Keywords: stylized facts, time series, stock prices, statistical models, efficient market model.

Introducción

El proyecto busca analizar los hechos estilizados en series de tiempo descritos por Cont (2001), para esto se descargan la información de cierre de las 500 empresas que conforma parte de el índice Standard & Poor's 500, también conocido como S&P 500 de los últimos 10 años, con la finalidad de ver si es posible poder predecir ciertos comportamientos por medio de modelos estadísticos y aprovecharlos para generar ganancias extras.

En un inicio expondrá la importancia de los hechos estilizados contrastando los puntos de vista de distintos autores. Por un lado, Eugene F. Fama y Kenneth R. French sostienen en "Anomalies in financial markets: A theoretical review" (1993) y "The cross-section of expected stock returns" (1992) que estos hechos han sido exagerados con respecto a cómo el impulso, la tendencia de un activo seguir con su comportamiento actual a corto plazo, y la relación precio-beneficio son consistentes con un modelo de mercado eficiente, modelos donde los precios de los activos reflejan toda la información relevante para tomar decisiones de inversión (Fama, 1965), debido a su naturaleza estos fenómenos pueden explicarse por factores de riesgo adicionales.

Por otro lado, John Y. Campbell, Andrew W. Lo y A. Craig MacKinlay argumentan en "The Econometrics of Financial Markets" (1997) que los mercados financieros no siempre son eficientes y que es posible detectar hechos estilizados que puedan explotarse para generar más ingresos. En "Momentum Crashes" (1999), Tobias J. Moskowitz y Mark Grinblatt también descubrieron evidencia de que el impulso, es un hecho persistente y estilizado y que las causas pueden estar relacionadas con los errores cognitivos y de comportamiento de los inversores.

Como se puede observar existen distintos puntos de vista sobre el papel que juegan los eventos estimados en los mercados financieros, algunos argumentan que son consistentes con un modelo de mercado eficiente y otros proponen que es posible detectar y explotar anomalías para obtener ganancias extras, el proyecto va dirigido a ver si es posible detectar y explotar esas anomalías.

Para mayor información sobre modelos de mercado eficiente, es recomendable revisarlas bibliografías mencionadas .

Marco teorico

Retornos logarítmicos

Los retornos logarítmicos son una medida de cambio en el valor de un activo financiero en un periodo de tiempo específico: diario, semanal, mensual, etcétera. Estos se calculan tomando la diferencia entre los logaritmos naturales del precio actual contra el anterior. Para nuestro caso tomaremos el precio ajustado ya que toma en cuenta los dividendos.

Estos son ampliamente utilizados en el ámbito financiero ya que poseen una propiedad bastante útil: la aditividad, lo que permite calcular el retorno total sumando todos los retornos del periodo. A esto le sumamos que las distribuciones de los retornos logarítmicos suelen ser significativamente más simétrica que los aritméticos, no en todos los casos como se ve en la **figura x**, pero en general se cumple.

Esta propiedad es la razón por la que se usan los retornos logarítmicos ya que son una herramienta bastante útil para modelar y predecir el comportamiento de los mercados financieros. Un ejemplo de su utilidad es como en la teoría de la eficiencia del mercado, los retornos logarítmicos se utilizan para evaluar la rentabilidad de una estrategia de inversión y para determinar si los precios de los activos son consistentes con los fundamentos económicos subyacentes.

Otro ejemplo es el uso que le da Tsay, este los usa para análisis de series de tiempo, los retornos logarítmicos se utilizan como una medida fundamental de la volatilidad de los mercados financieros. La volatilidad se define como la variabilidad en los retornos de un activo financiero, y los retornos logarítmicos son una forma estándar de medir esta variabilidad.

En particular, se utilizan para identificar los modelos ARIMA (autoregressive integrated moving average) y GARCH (generalized autoregressive conditional heteroskedasticity) que se ajusten mejor a los datos que se recopilarán. Estos son dos enfoques populares para modelar la volatilidad de los mercados financieros. Más adelante profundizaremos en ellos.

En resumen, los retornos logarítmicos son una medida importante para evaluar el rendimiento y la volatilidad de los activos financieros. Desde la perspectiva de la econometría en el análisis de series de tiempo, los retornos logarítmicos se utilizan ampliamente para modelar y predecir el comportamiento de los mercados financieros, especialmente en la evaluación de la eficiencia del mercado y en la modelización de la volatilidad. Por lo que los aprovechamos para identificar que modelos ARIMA y GARCH que se ajusten mejor a nuestros datos y veremos si estos efectivamente pueden ayudarnos en la optimización de estrategias de inversión.

Series de tiempo financieras

Las series de tiempo financieras son un tipo especial de serie de tiempo que se utiliza para analizar y predecir el comportamiento de los mercados financieros. En particular, las series de

tiempo financieras se utilizan para modelar la evolución de los precios de los activos financieros a lo largo del tiempo.

La ecuación general para una serie de tiempo financiera se puede escribir como:

$$Y_t = \mu + \varepsilon_t$$

donde Y_t es el valor de la serie de tiempo en el tiempo t , μ es la media de la serie de tiempo, y ε_t es el error aleatorio en el tiempo t .

El uso principal de las series de tiempo financieras es predecir el comportamiento futuro de los mercados financieros. Para hacer esto, se utilizan modelos de series de tiempo que buscan encontrar patrones en los datos históricos de los mercados financieros y utilizarlos para hacer predicciones sobre el futuro.

Los modelos más comunes utilizados en el análisis de series de tiempo financieras son los modelos ARIMA (Autoregressive Integrated Moving Average) y GARCH (Generalized Autoregressive Conditional Heteroskedasticity).

Las series de tiempo financieras son una herramienta importante para analizar y predecir el comportamiento de los mercados financieros. Los modelos ARIMA y GARCH son los modelos más comunes utilizados en el análisis de series de tiempo financieras y se utilizan para modelar patrones de autocorrelación, estacionalidad y volatilidad en los datos históricos del mercado financiero, temas que tocaremos más adelante.

Hechos estilizados

Nos detendremos a examinar las definiciones de las propiedades estadísticas estilizadas de los retornos del activo del artículo "Empirical properties of asset returns: stylized facts and statistical issues" de Rama Cont (2001), describiendo cada e ilustrando la mayoría.

Ausencia de autocorrelaciones: Las autocorrelaciones (lineales) de la rentabilidad de los activos suelen ser insignificantes, con la excepción de períodos intradiarios muy breves (20 minutos), en los que

los efectos de la microestructura son relevantes, estos se pueden ver como en la figura 1.¹




Figura 1 Graficas de ejemplos de patrones de autocorrelación, Miranda, Fuente: P. Miranda, J.(2021, June 10).

Colas pesadas: Para la mayoría de los conjuntos de datos examinados por Cont (2001), la distribución (incondicional) de los rendimientos parece tener una distribución tipo Pareto con un índice de cola que es finito, mayor que dos y menor que cinco. Se excluyen




Figura 2 QQ-Plot de rendimientos logarítmicos de Amazon en los últimos 10 años. Fuente elaboración propia

específicamente la distribución normal y las leyes estables con varianza infinita. Sin embargo, puede ser un desafío establecer la forma exacta de las colas. Estas se pueden ver en las figuras 2 y 3 el QQ-plot e histograma de los retornos logarítmicos de los últimos diez años de Amazon.²

Asimetría de ganancias/pérdidas: se observan caídas significativas en los precios de las acciones y los valores de los índices bursátiles, pero no hay aumentos correspondientemente significativos. Gaussianidad agregada: a medida que aumenta la disminuye la frecuencia de observación sobre la que se calculan los rendimientos, la distribución de los rendimientos se parece cada vez más a una distribución normal. En particular, la forma de distribución difiere según la escala de tiempo.³




Figura 3 Histograma de rendimientos logarítmicos de Amazon en los últimos 10 años
Fuente elaboración propia

desviaciones estándar de un activo financiero que se distribuyen de forma desigual en el tiempo, estas suelen ser constantes o duraderas en el tiempo, en una relación que asemeja un diálogo de pregunta respuesta, es decir, después de una pedido de alta volatilidad tienes uno de baja y viceversa., esto se puede ver las figura 4.⁶

Colas pesadas condicionales: la serie de tiempo residual todavía muestra colas pesadas incluso después de que los rendimientos se hayan ajustado para la agrupación de volatilidad (por ejemplo, utilizando modelos de tipo GARCH). Sin embargo, en comparación con la distribución

Gaussianidad agregacional: a medida que aumenta la escala de tiempo sobre la que se calculan los rendimientos, la distribución de los rendimientos se vuelve cada vez más normal. En particular, la forma de distribución difiere según la escala de tiempo.⁴

Intermitencia: Los retornos exhiben un alto grado de fluctuación en cualquier rango de tiempo. La ocurrencia de ráfagas erráticas en las series de tiempo de una amplia gama de estimadores de volatilidad sirve para cuantificar esto.⁵

Agrupación de volatilidad: Los grupos de volatilidad son conjuntos de




Figura 4 Gráfica de los los retornos logarítmicos de Kroger de Junio 22 a enero 2023
Fuente elaboración propia

^{4 5 6 7 8 9} Cont (2001)

incondicional de rendimientos, las colas no son tan fuertes. (Este concepto esta por ser trabajado).⁷

Deterioro lento de la autocorrelación en los rendimientos absolutos:⁸ la función de autocorrelación de los rendimientos absolutos decae gradualmente con el tiempo, esencialmente como una ley de potencia con exponente $[0.2, 0.4]$. Esto se ve ocasionalmente como una manifestación de confianza a largo plazo.⁸

Efecto de apalancamiento: la mayoría de las métricas de la volatilidad de un activo tienen una correlación negativa con los rendimientos de ese activo.⁹

Estacionariedad

El concepto de estacionariedad se refiere como una serie de tiempo tiene exactamente las mismas propiedad que si misma con un cambio en su tiempo, es decir su media y varianza son siempre iguales.

Existen dos tipos de estacionariedad, la fuerte la cual es al previamente mencionada y debil, para formalizar la definicion de esta ultima nos apoyaremos en la definición de J.

Brockwell(1973), el cual indica que si nos concentramos únicamente en las propiedades que dependen de los dos primeros momentos de las dos series de tiempo antes mencionadas ($\{X_t, t = 0, \pm 1, \dots\}$ y $\{X_{t+h}, t = 0, \pm 1, \dots\}$ con h como la diferencia de tiempo) podemos formalizar el concepto con las siguientes ecuaciones:

Let $\{X_t\}$ be a time series with $E(X_t^2) < \infty$. The **mean function** of $\{X_t\}$ is

$$\mu_X(t) = E(X_t).$$

The **covariance function** of $\{X_t\}$ is

$$\gamma_X(r, s) = \text{Cov}(X_r, X_s) = E[(X_r - \mu_X(r))(X_s - \mu_X(s))]$$

for all integers r and s .

Traducir y citar en nota de pie

$\{X_t\}$ is **(weakly) stationary** if

(i) $\mu_X(t)$ is independent of t ,

and

(ii) $\gamma_X(t + h, t)$ is independent of t for each h .

Traducir y citar en nota de pie

La estacionariedad tiene su importancia ya que nos permite aplicar técnicas estadísticas y matemáticas más simples y efectivas llevar a cabo un análisis de la serie temporal mas sencillo y asertivo, entre las tecnicas que se pueden usar garcais a esta estan la transformación de Fourier y la autocorrelación. Pero lo mas importante y que explotaremos más es que la estacionariedad facilita la identificación de patrones y tendencias en nuestro caso los hechos estilizados.

Las propiedades que aprovecharemos son que podemos tomar la funcion de autocorrelacion de la siguiente manera:

Sea la función de autocovarianza con diferecia de tiempo h

$$\gamma(h) = \text{Cov}(X_{t+h}, X_t), \quad h = 0, \pm 1, \pm 2, \dots$$

La funcion de autocorrelacion seria:

$$\rho(h) = \frac{\gamma(h)}{\gamma(0)}.$$

Para la demostacion y mayor profundizacion de esta checar J. Brockwell(fecha)

La covarianza es una medida estadística que se utiliza para medir la relación entre dos variables aleatorias. En particular, la covarianza mide cómo se mueven juntas dos variables aleatorias. Si dos variables tienen una covarianza positiva, significa que tienden a moverse en la misma dirección. Por otro lado, si tienen una covarianza negativa, significa que tienden a moverse en direcciones opuestas.

En el análisis de series de tiempo, la covarianza es especialmente importante porque nos ayuda a entender cómo se relacionan dos variables a lo largo del tiempo. En particular, la covarianza es una medida útil para medir la relación entre dos series de tiempo.

En el contexto de los modelos ARIMA y GARCH, la covarianza es una herramienta clave para entender y modelar la relación entre la media y la varianza de las series de tiempo. En el modelo ARIMA, la covarianza se utiliza para estimar los parámetros del modelo, y también para evaluar la precisión de las predicciones. En el modelo GARCH, la covarianza se utiliza para modelar la varianza condicional de la serie de tiempo, lo que nos permite capturar la volatilidad y la incertidumbre en la serie de tiempo.

En su libro "Analysis of Financial Time Seri", Ruey Tsay profundiza en la importancia de la covarianza en el análisis de series de tiempo. En particular, Tsay muestra cómo la covarianza

puede ayudarnos a identificar patrones y relaciones importantes en las series de tiempo, lo que nos permite hacer mejores predicciones y tomar mejores decisiones.

Por lo que la covarianza es una medida importante en el análisis de series de tiempo porque nos ayuda a entender cómo se relacionan dos variables a lo largo del tiempo. En particular, la covarianza es una herramienta clave en los modelos ARIMA y GARCH para modelar la relación entre la media y la varianza de las series de tiempo.

Modelos Ruido Blanco

Los modelos de ruido blanco son un tipo de modelo de series de tiempo que se utilizan para describir el comportamiento de una serie de tiempo que no tiene patrones o tendencias evidentes. En particular, el modelo de ruido blanco se utiliza para modelar una serie de tiempo cuyos valores son independientes e idénticamente distribuidos con media cero y varianza constante.

La ecuación de un modelo de ruido blanco se puede escribir como:

$$Y_t = \epsilon_t$$

donde Y_t es el valor de la serie de tiempo en el tiempo t , y ϵ_t es el error aleatorio en el tiempo t . En un modelo de ruido blanco, se asume que los errores ϵ_t tienen una distribución normal con media cero y varianza constante. Además, se asume que los errores ϵ_t son independientes entre sí.

La finalidad principal del modelo de ruido blanco es servir como un punto de referencia para comparar con otras series de tiempo. Si una serie de tiempo tiene patrones o tendencias evidentes, entonces no se ajustará bien a un modelo de ruido blanco. Por lo tanto, si una serie de tiempo no se ajusta bien a un modelo de ruido blanco, entonces es necesario buscar un modelo más complejo que tenga en cuenta las tendencias o patrones presentes en la serie de tiempo.

Además, el modelo de ruido blanco también se utiliza como una herramienta para diagnosticar si una serie de tiempo tiene patrones de autocorrelación o heterocedasticidad. Si los errores ϵ_t en un modelo de ruido blanco tienen patrones de autocorrelación, entonces esto sugiere que hay patrones en la serie de tiempo que no se están modelando adecuadamente. Por otro lado, si los errores ϵ_t en un modelo de ruido blanco tienen heterocedasticidad, entonces esto sugiere que la varianza de la serie de tiempo no es constante a lo largo del tiempo.

Los modelos de ruido blanco son una herramienta importante en el análisis de series de tiempo financieras. Su finalidad principal es servir como un punto de referencia para comparar con otras series de tiempo, y también se utilizan como una herramienta de diagnóstico para identificar patrones de autocorrelación o heterocedasticidad en las series de tiempo.

Modelo AR

Los modelos de autoregresión son un tipo de modelo de series de tiempo que se utilizan para modelar la relación entre una serie de tiempo y sus propias observaciones anteriores. En otras palabras, los modelos de autoregresión predicen el valor futuro de una serie de tiempo en función de sus valores pasados.

La ecuación general para un modelo de autoregresión de orden p , o $AR(p)$, se puede escribir como:

$$Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + \epsilon_t$$

donde Y_t es el valor de la serie de tiempo en el tiempo t , c es una constante, ϕ_1, \dots, ϕ_p son los coeficientes de autoregresión del modelo y ϵ_t es el error aleatorio en el tiempo t .

El uso principal de los modelos de autoregresión es predecir el comportamiento futuro de una serie de tiempo en función de su historia pasada. Estos modelos son útiles para predecir patrones de comportamiento repetitivos en los datos históricos, como patrones estacionales o cíclicos.

Una extensión de los modelos AR es el modelo ARIMA (Autoregressive Integrated Moving Average), que también incluye la diferenciación para hacer estacionaria la serie de tiempo antes de aplicar el modelo AR.

Los modelos de autoregresión son un tipo importante de modelo de series de tiempo que se utilizan para predecir el comportamiento futuro de una serie de tiempo en función de sus valores pasados. Estos modelos son útiles para modelar patrones repetitivos en los datos históricos y se pueden extender a modelos más complejos como el ARIMA para incluir otros factores que puedan influir en la serie de tiempo.

Modelo ARIMA ()

Los modelos ARIMA (Autoregressive Integrated Moving Average) son un tipo de modelo de series de tiempo que combinan los modelos de autoregresión (AR) y los modelos de media móvil (MA) con la diferenciación para hacer estacionaria la serie de tiempo antes de aplicar el modelo AR.

La ecuación general para un modelo ARIMA de orden (p,d,q) , se puede escribir como:

$$(1 - \phi_1 B - \dots - \phi_p B^p) (1 - B)^d Y_t = c + (1 + \theta_1 B + \dots + \theta_q B^q) \epsilon_t$$

donde Y_t es el valor de la serie de tiempo en el tiempo t , B es el operador de desplazamiento hacia atrás, c es una constante, ϕ_1, \dots, ϕ_p son los coeficientes de autoregresión, $\theta_1, \dots, \theta_q$ son los coeficientes de la media móvil, d es el orden de diferenciación y ϵ_t es el error aleatorio en el tiempo t .

La parte AR del modelo ARIMA, que representa la regresión autoregresiva, utiliza los valores pasados de la serie de tiempo para predecir el valor futuro de la serie. La parte MA del modelo ARIMA, que representa la media móvil, utiliza los errores pasados del modelo para predecir el valor futuro de la serie. La parte I del modelo ARIMA, que representa la diferenciación, se utiliza para hacer estacionaria la serie de tiempo.

El uso principal de los modelos ARIMA es predecir el comportamiento futuro de una serie de tiempo en función de su historia pasada y los patrones identificados en los datos. Estos modelos son útiles para modelar patrones estacionales, cíclicos y de tendencia en los datos históricos y se pueden utilizar para pronosticar el comportamiento futuro de la serie de tiempo en diferentes horizontes de tiempo. Además, los modelos ARIMA se pueden utilizar para identificar los efectos de los cambios en la serie de tiempo y para evaluar la efectividad de las políticas económicas y financieras en función de los cambios en la serie de tiempo. También se pueden utilizar para detectar anomalías y valores atípicos en la serie de tiempo.

Los modelos ARIMA son un tipo importante de modelo de series de tiempo que se utilizan para predecir el comportamiento futuro de una serie de tiempo en función de su historia pasada y los patrones identificados en los datos. Estos modelos son útiles para modelar patrones estacionales, cíclicos y de tendencia en los datos históricos y se pueden utilizar para pronosticar el comportamiento futuro de la serie de tiempo en diferentes horizontes de tiempo. También se pueden utilizar para identificar efectos y anomalías en la serie de tiempo.

Los modelos GARCH (Generalized Autoregressive Conditional Heteroskedasticity) son una clase de modelos utilizados en el análisis de series de tiempo financieras para modelar y predecir la volatilidad de los retornos de un activo financiero.

La volatilidad en los mercados financieros se refiere a la medida de la magnitud de los cambios de precios de un activo financiero en un período de tiempo determinado. En general, los modelos de volatilidad son útiles para los inversores que desean medir el riesgo de sus inversiones, ya que una alta volatilidad implica un mayor riesgo y una baja volatilidad implica un menor riesgo.

El modelo GARCH se basa en el modelo ARMA (Autoregressive Moving Average), que se utiliza para modelar los retornos de los precios de los activos financieros. El modelo GARCH añade una ecuación adicional que modela la volatilidad condicional de los retornos. La ecuación general del modelo GARCH (p, q) es:

$$\sigma_t^2 = \omega + \sum_{i=1}^p \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^q \beta_j \sigma_{t-j}^2$$

donde ε_t es el error en el tiempo t , σ_t^2 es la varianza condicional en el tiempo t , $\alpha_0, \alpha_1, \dots, \alpha_p$ y β_1, \dots, β_q son parámetros que se estiman a partir de los datos.

La ecuación para la varianza condicional en el tiempo t es una combinación lineal de los errores al cuadrado en los tiempos $t-1, t-2, \dots, t-p$ y la varianza condicional en los tiempos $t-1, t-2, \dots, t-q$. El parámetro α_0 es una constante que determina el nivel de volatilidad condicional, mientras que los parámetros α_i y β_j determinan la tasa de ajuste de la varianza condicional a los errores al cuadrado y la varianza condicional pasada, respectivamente.

Los modelos GARCH se utilizan principalmente para predecir la volatilidad futura de los retornos de los precios de los activos financieros, lo que permite a los inversores tomar decisiones informadas sobre la gestión de su cartera y la gestión del riesgo. También se utilizan en la construcción de modelos de valuación de opciones, ya que la volatilidad es un factor clave en la determinación del precio de las opciones.

Los modelos GARCH son útiles para modelar y predecir la volatilidad condicional de los retornos de los precios de los activos financieros, lo que permite a los inversores tomar decisiones informadas sobre la gestión de su cartera y la gestión del riesgo.

Resultados o avances:

En primera instancia, se descargó la información de las 500 empresas que conforman el S&P500. Se descargó la información de cierre diario de los últimos 10 años, la cual está conformada por el símbolo (identificador), la compañía, el identificador SEDOL, el peso, el sector, las acciones en manos, la moneda local (USD), la fecha, el precio de apertura, el cierre, el alto, el bajo y el volumen, así como el precio ajustado. Con esta base de datos se obtuvieron más de 1,240,000 filas.

Se verificó que no hubiera información faltante ni datos en formatos diferentes. No hubo ningún problema en este aspecto. Lo siguiente fue descartar las columnas no deseadas, tales como SEDOL, peso, sector y acciones en manos, y moneda local (USD).

A continuación, se procedió a calcular los retornos logarítmicos la columna de adjusted, y graficar histogramas de estos retornos:

Figura con histogramas

En estos gráficos podemos observar cómo la mayoría respeta la simetría, teniendo poca curtosis.

se graficaron los QQ plots para ver el comportamiento de las colas. Se esperaba ver colas pesadas, lo cual se confirmó como se puede apreciar en la siguiente figura:

Figura con QQ plots

Posteriormente, se graficó la función de autocorrelación (ACF) y la función de autocorrelación parcial (PACF) con la finalidad de poder observar la correlación general de los retornos logarítmicos y la correlación de la serie de tiempo y sus valores retrasados, respectivamente. Los resultados fueron los siguientes:

Figura con ACF y PACF

En estos se pudo ver que algunas observaciones presentaban cierto nivel de correlación mientras que otras no. Este patrón puede observarse como sigue:

Figura con ACF y PACF

Nelson me dio un ejemplo de cómo se mantenían en rango y bajaban en escalera, mientras que en otros casos alternaban entre un gran pico y luego bajaban.
Tuve un accidente y perdí las anotaciones de esto

El siguiente paso fue determinar qué modelo se ajustaba mejor a los datos. Para esto, se utilizó la función `auto.arima` para obtener los valores óptimos de los parámetros $AR(p)$, número de integraciones y $MA(q)$. Los resultados fueron los siguientes:

Histograma de resultado de `auto.arima`

Como se pudo observar, la mayoría de los modelos ajustados fueron $AR(1)$ o $AR(2)$. En algunos casos especiales se encontró un $AR(5)$, lo cual puede ser relativamente fácil de predecir. Sin embargo, en su mayoría estos modelos no son óptimos para predecir ya que... Tuve un accidente y perdí las anotaciones de esto

Bibliografía

Campbell, J. Y., Lo, A. W., & MacKinlay, A. C. (1997). The econometrics of financial markets. In The econometrics of financial markets. Princeton University press.

Cont, R. (2001). Empirical properties of asset returns: stylized facts and statistical issues. Quantitative finance, 1(2), 223.

Daniel, K. D., & Moskowitz, T. J. (2013). Momentum crashes. Swiss Finance Institute Research Paper, (13-61), 14-6.

Eugene F. Fama y Kenneth R. French (1993) Anomalies in financial markets: A theoretical review, Journal of Financial Economics.

Eugene F. Fama y Kenneth R. French (1992) The cross-section of expected stock returns, Journal of Finance, vol 47, núm 2.

Fama, E. F. (1965). The behavior of stock-market prices. The journal of Business, 38(1), 34-105.

Fama, E. F. (1970). Session Topic: Stock Market Price Behavior Session Chairman: Burton G.

Malkiel Efficient Capital Markets: A Review Of Theory And Empirical Work. The Journal of Finance, 25(2), 383-417.

Miranda, P., Miranda, J.(2021, June 10). Autocorrelación. Retrieved February 14, 2023, from <https://todoeconometria.wordpress.com/2017/08/08/autocorrelacion/>

Ruey S. Tsay (2005) Analysis of Financial Time Series John Wiley & Sons, Inc., Hoboken, New Jersey.